به نام خدا

گزارش پروژه بیوانفورماتیک

Mitochondrial Short Variant Discovery Pipeline (GATK Best Practices)

مدرس :دکتر درزی

تهیه‌کننده : مهدی یعقوب زاده

تاریخ : 1404/06/25

این پایپلاین برای شناسایی واریانت‌های کوچک SNVs و Indels در ژنوم میتوکندری طراحی شده است.

نیاز به داده‌های توالی‌یابی FASTQ یا BAM ، ژنوم مرجع میتوکندری(rCRS) ، و ابزارهایGATK

مراحل شامل هم‌ترازی، شناسایی واریانت‌ها باMutect2 ، و فیلتر کردن نتایج است.

GATKنسخه 4.6.1.0 نصب‌شده و آماده استفاده است.

BWAنسخه 0.7.17 برای هم‌ترازی توالی‌ها نصب‌شده است.

Samtoolsنسخه 1.19.2 برای مدیریت فایل‌های BAM/SAM نصب‌شده است.

Javaنسخه 21.0.7 برای اجرای GATK و Picard نصب‌شده است.

Picard هم نصب شد.

دانلود ژنوم مرجع میتوکندری(rCRS)

ژنوم مرجع میتوکندری رو از NCBI دانلود می‌کنیم:

```
(base) bioar@DESKTOP-LQBNPNF:~/mito_project$ wget -O rCRS.fasta "https://www
.ncbi.nlm.nih.gov/nuccore/NC_012920.1?report=fasta&format=text"
```

فایل FASTA رو تمیز می‌کنیم : (هدرهای اضافی NCBI رو حذف می‌کنیم)

```
(base) bioar@DESKTOP-LQBNPNF:~/mito_project$ grep -v ">" rCRS.fasta | tr -d
'\n' > chrM.fasta
echo ">chrM" | cat - chrM.fasta > temp.fasta && mv temp.fasta chrM.fasta
```

ایجاد فایل های شاخص(ایندکس):
برای Alignment استفاده از BWA
bwa index chrM.fasta

استفاده از samtools برای مدیریت BAM

samtools faidx chrM.fasta

برای GATK ایجاد دیکشنری:

picard CreateSequenceDictionary -R chrM.fasta -O chrM.dict

فایل dictionary برای ژنوم مرجع (chrM.dict) با دستور picard CreateSequenceDictionary REFERENCE=chrM.fasta OUTPUT=chrM.dictایجاد شد. فایل‌های ژنوم مرجع و شاخص‌ها : chrM.fasta, chrM.dict, chrM.fasta.amb, chrM.fasta.ann, chrM.fasta.bwt, chrM.fasta.fai, chrM.fasta.pac, chrM.fasta.sa."

هم‌ترازی باBWA :

هم‌ترازی (alignment) فایل‌های FASTQ با ژنوم مرجع GRCh38 MT با استفاده ازBWA

ایجاد فایل های شاخص(ایندکس):

```
(base) bioar@DESKTOP-LQBNPNF:~/mito_project$ bwa index ~/mito_project/Homo_sapiens.GRCh38.dna.chromoso
me.MT.fa
[bwa_index] Pack FASTA... 0.00 sec
[bwa_index] Construct BWT for the packed sequence...
[bwa_index] 0.00 seconds elapse.
[bwa_index] Update BWT... 0.00 sec
[bwa_index] Pack forward-only FASTA... 0.00 sec
[bwa_index] Construct SA from BWT and Occ... 0.00 sec
[main] Version: 0.7.17-r1188
[main] CMD: bwa index /home/bioar/mito_project/Homo_sapiens.GRCh38.dna.chromosome.MT.fa
[main] Real time: 0.069 sec; CPU: 0.012 sec
```

فایل‌های FASTQ رو با BWA mem هم‌تراز می‌کنیم:

```
bwa mem -t 4 ~/mito_project/Homo_sapiens.GRCh38.dna.chromosome.MT.fa \
~/mito_project/a_1.fastq.gz ~/mito_project/a_2.fastq.gz \
> ~/mito_project/aligned_reads.sam
```

فایل SAM رو به BAM تبدیل می‌کنیم:

```
samtools view -bS ~/mito_project/aligned_reads.sam > ~/mito_project/aligned_reads.ba
```

BAM رو مرتب می کنیم :

```
samtools sort ~/mito_project/aligned_reads.bam -o ~/mito_project/sorted_aligned_rea
```

افزودن read group :

که با picard انجامش میدیم

```
picard AddOrReplaceReadGroups \
I=~/mito_project/sorted_aligned_reads.bam \
O=~/mito_project/sorted_aligned_reads_with_RG.bam \
RGID=sample_id RGLB=lib1 RGPL=illumina RGPU=unit1 RGSM=sample_name
```

ایجاد فایل شاخص BAM

برای استفاده توGATK ، فایل شاخص BAM می‌سازیم:

```
samtools index ~/mito_project/sorted_aligned_reads_with_RG.bam
```

افزودن read group و آماده‌سازی برای Variant Calling

افزودن read group با Picard :

```
picard AddOrReplaceReadGroups \
I=~/mito_project/sorted_aligned_reads.bam \
O=~/mito_project/sorted_aligned_reads_with_RG.bam \
RGID=sample_id RGLB=lib1 RGPL=illumina RGPU=unit1 RGSM=sample_name
```

ایجاد فایل شاخص BAM:

```
samtools index ~/mito_project/sorted_aligned_reads_with_RG.bam
```

خروجی دو مرحله قبل :

```
sorted_aligned_reads_with_RG.bam
sorted_aligned_reads_with_RG.bam.bai
```

Variant Calling با GATK :

در ابتدا : variant calling با Mutect2

```
gatk Mutect2 \
  -R ~/mito_project/Homo_sapiens.GRCh38.dna.chromosome.MT.fa \
  -I ~/mito_project/sorted_aligned_reads_with_RG.bam \
  -O ~/mito_project/variants.vcf \
  --mitochondria-mode
```

این دستور واریانت‌های کوچک SNVs و Indels رو تو فایل variants.vcf ذخیره می‌کنه.

در کل مرحله آماده‌سازی BAM فایل با افزودن read group و فایل شاخص آماده شد. آماده‌سازی برای variant calling با GATK Mutect2 انجام شد.

برای شناسایی واریانت‌های کوچک (SNVs و Indels) در داده‌های میتوکندری، از ابزار Mutect2 در حالت mitochondria-mode--استفاده می‌کنیم. این ابزار برای داده‌های میتوکندری بهینه شده و با ژنوم مرجع GRCh38 MT کار می‌کنه.

دو تا فایل با نام variants.vcf و variants.vcf.idx

بهمون داده این دستور

تعداد خطوط VCF برای یه نگاه سریع به واریانت‌ها:

```
(base) bioar@DESKTOP-LQBNPNF:~/mito_project$ grep -v "^#" ~/mito_project/variants.vcf | wc -l
652
```

این تعداد واریانت‌های شناسایی‌شده (غیر از هدر) رو نشون می‌ده.

فیلتر کردن واریانت‌ها:

بعد از تولید فایل variants.vcf ، باید واریانت‌ها رو فیلتر کنیم تا واریانت‌های باکیفیت بالا رو جدا کنیم. طبق پایپلاین میتوکندری GATK ، از ابزار FilterMutectCalls استفاده می‌کنیم

```
gatk FilterMutectCalls \
  -R ~/mito_project/Homo_sapiens.GRCh38.dna.chromosome.MT.fa \
  -V ~/mito_project/variants.vcf \
  -O ~/mito_project/filtered_variants.vcf \
  --mitochondria-mode
```

این دستور واریانت‌های خام رو فیلتر می‌کنه و واریانت‌های باکیفیت رو تو filtered_variants.vcf ذخیره می‌کنه.

```
(base) bioar@DESKTOP-LQBNPNF:~/mito_project$ grep -v "^#" ~/mito_project/filtered_variants.vcf | wc -l
652
```

میتوکندری ژنوم کوچیکی داره (16569 bp) و واریانت‌ها معمولاً محدودن.

تعداد 652 واریانت در variants.vcf (قبل از فیلتر) و filtered_variants.vcf(بعد از فیلتر) نشون می‌ده که FilterMutectCalls هیچ واریانتی رو به‌عنوان کم‌کیفیت حذف نکرده.

دلایل برابر بودنشون : کیفیت بالای داده‌ها

داده ها (از a_1.fastq.gz وa_2.fastq.gz) کیفیت خوبی دارن و همه واریانت‌ها معیارهای فیلترمثل عمق پوشش، کیفیتread ها رو پاس کردن.

حالت میتوکندری: گزینه mitochondria-mode-- در Mutect2 و FilterMutectCallsبرای میتوکندری بهینه شده و فیلترهای ملایم‌تری اعمال می‌کنه، چون میتوکندری تنوع ژنتیکی محدودی داره.

داده‌های :WES چون داده‌ها Whole Exome Sequencing هستن، ممکنه فقط واریانت‌های خاصی تو ناحیه میتوکندری شناسایی شده باشن که همشون معتبرن.

ستون فیلتر و بررسی کردیم :

```
(base) bioar@DESKTOP-LQBNPNF:~/mito_project$ grep -v "^#" ~/mito_project/filtered_variants.vcf | awk '
{print $7}' | sort | uniq -c
      2 FAIL
    413 PASS
     59 base_qual
      1 base_qual;map_qual;weak_evidence
     38 base_qual;weak_evidence
      9 map_qual
      1 map_qual;strand_bias
      6 map_qual;weak_evidence
      1 position
      1 position;weak_evidence
     40 strand_bias
      5 strand_bias;weak_evidence
     76 weak_evidence
```

ستون FILTER در فایل filtered_variants.vcf بررسی شد:

413 واریانتPASS ، 239 واریانت غیر PASS شاملbase_qual ،
map_qual، strand_bias، weak_evidence.
تعداد کل واریانت‌ها: 652

413 واریانت (63%) کیفیت خوبی دارن و برای آنالیز بعدی مناسبن .

بقیه واریانت‌ها به دلایل مختلفی مثل کیفیت پایین باز(base_qual) ، مشکلات نگاشت(map_qual) ، سوگیری رشته(strand_bias) ، یا شواهد ضعیف (weak_evidence)فیلتر شدن .

این که تعداد زیادی واریانت غیر PASS داریم (239 تا)، برای داده‌های Whole Exome Sequencing (WES)قابل انتظاره، چون WES روی ژنوم هسته‌ای تمرکز داره و ممکنهread های میتوکندری کیفیت متغیری داشته باشن .

تعداد 652 واریانت برای میتوکندری (16569 bp) بالاست، که احتمالاً به دلیل پوشش بالایread ها در داده‌هایWES هست

آنوتیشن واریانت‌ها:

حالا که تأیید کردیم فایل filtered_variants.vcf آماده‌ست و 413 واریانت PASSداریم، می‌تونیم بریم سراغ آنهوتیشن واریانت‌ها با VEP Variant Effect Predictor تا تأثیرات بیولوژیکی واریانت‌ها مثلmissense ، synonymous، یا non-coding رو مشخص کنیم.

```
vep --cache --dir_cache /home/bioar/vep_cache \
--input_file ~/mito_project/filtered_variants.vcf \
--output_file ~/mito_project/annotated_variants.vep.vcf \
--vcf --species homo_sapiens --assembly GRCh38 \
--offline
```

این دستور فایل filtered_variants.vcf با (652 واریانت، 413 PASS) رو آنوتیشن کنه و خروجی رو در annotated_variants.vep.vcf ذخیره کنه.

گزارش تحلیل واریانت‌های میتوکندری باVEP :

در این پروژه، پس از اجرای پایپلاین شناسایی واریانت‌های کوتاه میتوکندری)مطابق مستندات(GATK ، فایل خروجی filtered_variants.vcf به‌وسیله‌ی نرم‌افزار **Ensembl Variant Effect Predictor (VEP)** نسخه 113 آنالیز و Annotate شد. هدف از این مرحله، افزودن اطلاعات عملکردی و بیولوژیکی به هر واریانت است، از جمله اثر آن روی پروتئین، موقعیت ژنی، و پیش‌بینی اثرات مخرب.

مشخصات اجرایVEP

- **نسخه Ensembl API:** 113.0
- **حالت اجرا :**آفلاین با استفاده از کش محلی
- **کش**/homo_sapiens/113_GRCh38
- **ژنوم مرجع:** GRCh38.p14
- **تعداد کل واریانت‌ها:** 652 رکورد
- **نوع داده ورودی :**خروجی فیلترشده‌ی(VCF) Mutect2

نوع واریانت ها :

نوع واریانت	تعداد
SNV (تغییر تک‌نوکلئوتیدی)	521
جانشینی (substitution)	63
Insertion (درج)	29
Deletion (حذف)	20
Indel	16
تغییر توالی کلی (alteration)	3

پیامدهای شدیدتر:

پیامد	تعداد
Missense variant	135
Synonymous variant	140
Non-coding transcript exon	334
Stop gained	5
Frameshift variant	6
Start lost	2
Inframe insertion	3
Protein altering variant	1
Upstream gene variant	26

ژن‌های تحت تأثیر

- تعداد ژن‌های همپوشان با واریانت‌ها :**37 ژن**
- همه ژن‌ها روی کروموزوم **MT**قرار دارند (ژنوم میتوکندری).

پیش‌بینی اثر عملکردی SIFT) و(PolyPhen

SIFT(پیش‌بینی اثر آمینواسید جایگزین بر عملکرد پروتئین) :

- Tolerated: 10
- Tolerated (low confidence): 31
- Deleterious: 19
- Deleterious (low confidence): 72

PolyPhen (پیش‌بینی احتمال تخریب ساختار/عملکرد پروتئین) :

- Benign: 49
- Possibly damaging: 19
- Probably damaging: 64

توضیح:

- SIFTمقادیر «Deleterious» را به عنوان اثر مخرب بالقوه معرفی می‌کند.
- PolyPhenمقادیر «Probably damaging» را به عنوان اثر مخرب با اطمینان بالا می‌شناسد.

VEP run statistics

VEP version (API)	113.0 (113)
Annotation sources	Cache: `/home/bioar/.vep/homo_sapiens/113_GRCh38`
Species	homo_sapiens
Command line options	`--assembly GRCh38 --cache --dir_cache /home/bioar/.vep --everything --force_overwrite --input_file /home/bioar/mito_project/filtered_variants.vcf --offline --output_file /home/bioar/mito_project/annotated_variants.vep.vcf --species homo_sapiens --vcf`
Start time	2025-08-15 10:37:43
End time	2025-08-15 10:37:48
Run time	5 seconds
Input file	`/home/bioar/mito_project/filtered_variants.vcf`
Output file	`/home/bioar/mito_project/annotated_variants.vep.vcf`

Data version

1000genomes	phase3
COSMIC	99
ClinVar	202404
HGMD-PUBLIC	20204
assembly	GRCh38.p14
dbSNP	156
gencode	GENCODE 47
genebuild	GENCODE47
gnomADe	v4.1
gnomADg	v4.1
polyphen	2.2.3
regbuild	1.0
sift	6.2.1

General statistics

Lines of input read	652
Variants processed	652
Variants filtered out	0
Novel / existing variants	438 (67.2) / 214 (32.8)
Overlapped genes	37
Overlapped transcripts	37
Overlapped regulatory features	0

Variant classes

Variant class	Count
sequence_alteration	3
indel	16
deletion	20
insertion	29
substitution	63
SNV	521

Consequences (most severe)

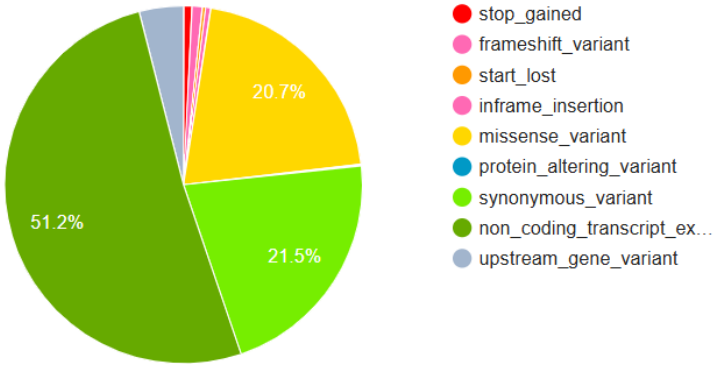

Consequence type	Count
stop_gained	5
frameshift_variant	6
start_lost	2
inframe_insertion	3
missense_variant	135
protein_altering_variant	1
synonymous_variant	140
non_coding_transcript_exon_variant	334
upstream_gene_variant	26

Consequences (all)

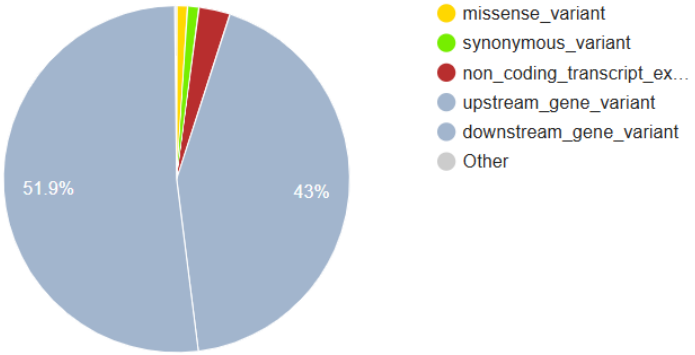

Consequence type	Count
stop_gained	5
frameshift_variant	7
start_lost	2
inframe_insertion	3
missense_variant	138
protein_altering_variant	1
stop_retained_variant	3
synonymous_variant	142
non_coding_transcript_exon_variant	392
upstream_gene_variant	5,782
downstream_gene_variant	6,973

Coding consequences

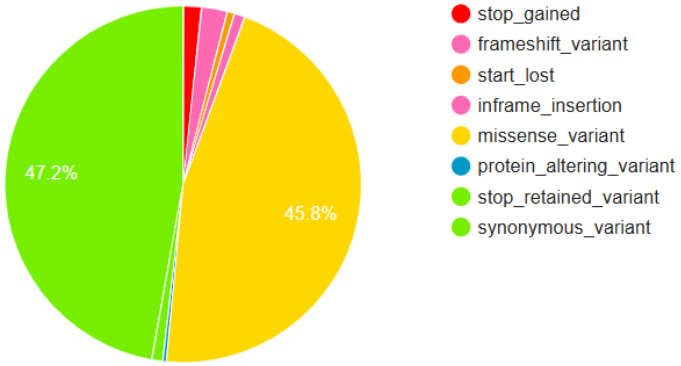

Consequence type	Count
stop_gained	5
frameshift_variant	7
start_lost	2
inframe_insertion	3
missense_variant	138
protein_altering_variant	1
stop_retained_variant	3
synonymous_variant	142

SIFT summary

Prediction	Count
tolerated	10
deleterious	19
tolerated_low_confidence	31
deleterious_low_confidence	72

PolyPhen summary

Prediction	Count
possibly_damaging	19
benign	49
probably_damaging	64

Variants by chromosome

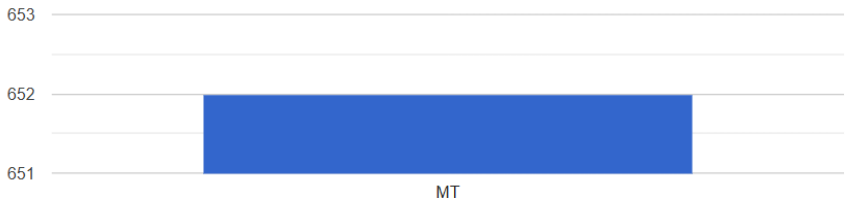

Chromosome	Count
MT	652

Position in protein

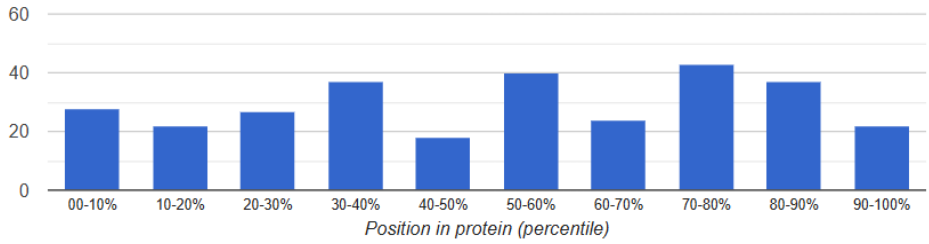

نتیجه:

در این آنالیز، مجموعاً 652 واریانت روی ژنوم میتوکندری شناسایی و Annotateشدند. بیشتر این واریانت‌ها در نواحی **non-coding**یا به صورت **synonymous**قرار داشتند، که به‌طور مستقیم منجر به تغییر توالی پروتئین نمی‌شوند. با این حال، تعدادی واریانت با اثرات بالقوه شدیدتر نظیر **missense**، **stop gained**و **frameshift**نیز مشاهده شدند که می‌توانند بر عملکرد ژن‌های میتوکندری تأثیرگذار باشند.